

**Fundação Getulio Vargas  
Escola de Matemática Aplicada**

**Wellington José**

**Resumo Álgebra Linear**

Rio de Janeiro  
2021

## Ortogonalidade

Seja  $E$  um espaço vetorial. Diremos que  $u$  e  $v$  são ortogonais se  $v^T u = 0$  e escrevemos  $v \perp u$ .

- $v^T u = v \cdot u$
- $\|v + u\|^2 = \|v\|^2 + \|u\|^2$

Sejam  $V$  e  $U$  dois subespaços vetoriais de  $E$ . Diremos que  $V \perp U$  se  $v \perp u$ , para todo  $v \in V$  e  $u \in U$

- $w \in V \cap U \iff w = 0$

## Ortogonalidade e os espaços fundamentais

- $N(A) \perp C(A^T)$
- $C(A) \perp N(A^T)$

## Complemento Ortogonal

$$V^\perp = \{w \in E; w \perp V\}$$

- $V^\perp$  é um subespaço de  $E$

Seja  $\{v_1, \dots, v_k\}$  gera  $V$ . Então

- $w \in V^\perp \iff w \perp v_i \forall i \in I_k$

- Defina  $A = \begin{bmatrix} v_1^T \\ \vdots \\ v_k^T \end{bmatrix}$ . Então  $V^\perp = N(A)$  e podemos achar uma base para  $V^\perp$

- $V \cap V^\perp = \{0\}$
- $\dim V + \dim V^\perp = \dim E$
- $V = (V^\perp)^\perp$

## Decomposição Ortogonal

**Teorema 1** *Todo vetor  $x \in E$  pode ser escrito como  $x = v + v^\perp$ , onde  $v \in V$  e  $v^\perp \in V^\perp$ , essa decomposição é única.*

## Projeção Ortogonal

- Seja  $a$  e  $b$  dois vetores num espaço vetorial  $E$ . A projeção de  $b$  em  $a$ :

$$p = \frac{aa^T}{a^T a} \cdot b$$

## Matriz de Projeção

A matriz de projeção  $P$  pode ser escrita como

$$P = \frac{aa^T}{a^T a}$$

Com as propriedades:

- $P$  tem posto 1
- $P$  é simétrico
- $P^2 = P$

## Projeção no plano

Seja  $a_1$  e  $a_2$  uma base para o plano. Então queremos achar  $x_1$  e  $x_2$  tal que o vetor projetado  $p$  possa ser escrito como  $x_1 a_1 + x_2 a_2$ , podemos entender que o plano pode ser entendido como o espaço coluna de  $A = [a_1 \ a_2]$ , então temos que fazer a projeção no caso mais geral em  $C(A)$

## Projeção em $C(A)$

Dado  $b$ , achar  $x$  tal que  $a_i^T(b - Ax) = 0$  para todo  $i$  onde  $a_i \in C(A)$ , equivalente a  $A^T Ax = A^T b$ , se  $A^T A$  é inversível (note que é quadrada), então  $P = A(A^T A)^{-1} A^T$ , se  $A$  for inversível então  $P = I$ .

obs.: A projeção em  $N(A^T)$  é  $I - P$  onde  $P$  é a projeção em  $C(A)$ .

$$A^T A$$

**Teorema 2**  $A^T A$  tem inversa se e somente se as colunas de  $A$  são LI.

## Mínimos quadrados

Como nem sempre  $Ax^* = b$  tem solução podemos projetar  $b$  em  $C(A)$  e  $Ax^* = b \rightarrow A^T Ax^* = A^T b \rightarrow x^* = (A^T A)^{-1} A^T b$  assim  $x^*$  é uma solução em mínimos quadrados.

## Mínimos Quadrados - Caso Geral

Note que  $x^* = (A^T A)^{-1} A^T b$ , onde  $A = \begin{bmatrix} 1 & t_1 \\ 1 & t_2 \\ \vdots & \vdots \\ 1 & t_m \end{bmatrix}$

Além disso  $A^T A = \begin{bmatrix} m & \sum t_i \\ \sum t_i & \sum t_i^2 \end{bmatrix}$  e  $A^T b = \begin{bmatrix} \sum b_i \\ \sum t_i b_i \end{bmatrix}$

## Vetores Ortonormais

Os vetores  $q_1, \dots, q_k$  são ditos ortogonais se  $q_i^T q_j = 0$ , para  $i \neq j$  diremos que são ortonormais se além de ortogonais, eles forem unitários, ou seja,  $q_i^T q_i = 1$  para qualquer  $i$ .

**Lema 3** Vetores ortogonais são sempre LI

## Matriz Ortogonais

Diremos que uma matriz é ortogonal se suas colunas são ortogonais ou  $Q_{m \times n}$  é ortogonal se  $Q^T Q = I_{n \times n}$ . Se  $Q$  for quadrada então  $Q^T = Q^{-1}$

- Matrizes ortogonais preservam o comprimento:  $|Qx| = |x|$

## Processo de Gram-Schmidt com 2 vetores

Vamos começar com dois vetores LI  $v_1$  e  $v_2$ . Queremos achar  $u_1$  e  $u_2$  tais que  $u_1 \perp u_2$  e  $\text{span}(v_1, v_2) = \text{span}(u_1, u_2)$ , podemos tomar  $u_1 = v_1$  e  $u_2 = v_2 - \text{proj}_{u_1} v_2$  e para criar vetores ortonormais basta fazer  $q_i = \frac{u_i}{|u_i|}$

$$v_1, v_2 \text{ (LI)} \rightarrow u_1, u_2 \text{ (Ortogonal)} \rightarrow q_1, q_2 \text{ (Ortonormal)}$$

## Processo de Gram-Schmit geral

Com 3 vetores  $v_1, v_2$  e  $v_3$  criamos  $u_1$  e  $u_2$  como acima e  $u_3 = v_3 - \text{proj}_{u_1} v_3 - \text{proj}_{u_2} v_3$  e assim  $u_1 \cdot u_3 = u_2 \cdot u_3 = 0$ . E o processo se repete para  $n$  vetores.

## Determinante

Se  $A$  é uma matriz  $2 \times 2$  então  $\det(A) = a_{11}a_{22} - a_{12}a_{21}$

Propriedades:

- Determinante de uma matriz permutação é 1 ou -1 dependendo se a matriz troca um número par ou ímpar de linhas.
- Se duas linhas da matriz são iguais, então o determinante é zero.
- Somar  $\lambda \in \mathbf{R}$  vezes a linha  $i$  na linha  $j$  não muda o determinante.
- Se uma linha da matriz é de zeros então o determinante é zero.
- Determinante de uma matriz diagonal é o produto dos valores da diagonal.
- Determinante de uma matriz triangular é o produto dos valores na diagonal.
- Determinante de uma matriz é  $\pm$  produto dos pivôs.
- $\det AB = \det A \det B$
- $\det A^{-1} = \frac{1}{\det A}$
- $\det A^T = \det A$
- $|\det Q| = 1$ , se  $Q$  é uma matriz ortogonal.

## Fórmula dos pivôs

Como  $\det A = \pm \prod p_i$ , onde  $p_i$  é o  $i$ -ésimo pivô,  $p_i$  pode ser escrito como (supondo que exista ao menos um pivô).

$$p_i = \frac{\det A_i}{\det A_{i-1}}$$

## Co-fatores

Ver em [Explicação Co-fator](#).

## Inversa usando determinante

Se  $\det A \neq 0$ , então  $A^{-1} = \frac{1}{\det A} C^T$ , onde  $C$  é a matriz de cofatores de  $A$ .

## Regra de Cramer

Usando a fórmula acima temos que a solução de  $Ax = b$  pode ser escrita como

$$x = \frac{1}{\det A} C^T b$$

A Regra de Cramer é outra forma de olhar a equação:

$$x_j = \frac{\det B_j}{\det A}$$

onde  $B_j$  é a matriz  $A$  trocando a coluna  $j$  por  $b$ .

## Área de um triângulo em $\mathbb{R}^2$

A área de um triângulo em  $\mathbb{R}^2$  é definida dadas as coordenadas dos vértices por:

$$A = \frac{1}{2} \begin{vmatrix} 1 & 1 & 1 \\ x_1 & x_2 & x_3 \\ y_1 & y_2 & y_3 \end{vmatrix}$$

## Produto Vetorial em $\mathbb{R}^3$

O produto vetorial de dois vetores  $u, v \in \mathbb{R}^3$  é definido como

$$u \times v = \begin{vmatrix} e_1 & e_2 & e_3 \\ u_1 & u_2 & u_3 \\ v_1 & v_2 & v_3 \end{vmatrix} = (u_2v_3 - u_3v_2)e_1 + (u_3v_1 - u_1v_3)e_2 + (u_1v_2 - u_2v_1)e_3$$

Onde  $e_i$  é um vetor unitário, e vale:

- $v \times u = -(u \times v)$
- $u \cdot (u \times v) = v \cdot (u \times v) = 0$
- $u \times u = 0$
- $|u \times v| = |u||v|\sin \theta$
- $(u \times v) \cdot w = 0 \Leftrightarrow u, v, w$  estão no mesmo plano.

## Autovalores e Autovetores

**Definição 1** Diremos que  $\lambda$  é um **autovalor** de  $A$  se existe  $x$  tal que  $Ax = \lambda x$  e  $x$  é dito **autovetor** de  $A$  e por linearidade  $\alpha x$  é autovetor para  $\forall \alpha \in \mathbb{R}$ .

Se 0 é autovalor de  $A$ , os autovetores serão os elementos de  $N(A)$ . Além disso,  $A$  é dito singular.

## Calculando Autovalores e Autovetores

$\lambda$  é um **autovalor** de  $A$  se e só se  $A - \lambda I$  é singular, o que é equivalente a  $\det(A - \lambda I) = 0$ , onde

$$p(\lambda) = \det(A - \lambda I)$$

É dito o **polinômio característico** de  $A$ , e os autovalores são as raízes desse polinômio,  $p$  é de grau  $n$  e portanto toda matriz tem  $n$  autovalores (podendo ser repetidos ou complexos), daí os **autovetores** são calculados a partir do sistema  $(A - \lambda I)x = 0$ . Note que autovetor  $\in N(A - \lambda I)$ .

## Propriedades

- Se  $Ax = \lambda x$  e  $Bx = \mu x$ , então  $\lambda + \mu$  é autovalor de  $A + B$ .
- $A^k x = \lambda^k x$
- Se  $\lambda \neq 0$  e  $\lambda$  é autovalor de  $A$ , então  $A^{-1}x = \frac{1}{\lambda}x$ , ou seja  $\frac{1}{\lambda}$  é autovalor da inversa.
- $E_\lambda = \{x; Ax = \lambda x\}$  é um subespaço vetorial.
- $p(\lambda) = (-1)^n \det(\lambda I - A) = (-1)^n (\lambda^n + c_{n-1}\lambda^{n-1} + \dots + c_1\lambda + c_0)$
- $\det A = \lambda_1 \cdots \lambda_n$
- $\text{trace}(A) := a_{11} + \dots + a_{nn} = \lambda_1 + \dots + \lambda_n$

## Diagonalização

**Teorema 4** *Os autovetores são LI quando os seus respectivos autovalores são distintos.*

Seja  $A$  matriz com  $n$  autovetores LI,  $x_1, \dots, x_n$  e os respectivos autovalores  $\lambda_1, \dots, \lambda_n$ . Tome  $S = [x_1 \cdots x_n]$ , assim

$$S^{-1}AS = \Lambda$$

Onde  $\Lambda$  é uma matriz diagonal com os termos  $\lambda_i$  e  $AS = S\Lambda$

## MA e MG

A **multiplicidade algébrica (MA)** de um autovalor  $\lambda$  como multiplicidade da raiz no polinômio característico. Já a **multiplicidade geométrica (MG)** de um autovalor  $\lambda$  é a  $\dim(N(A - \lambda I)) = \dim(E_\lambda)$ . Se  $MG = MA$  para todo autovalor, então  $A$  é diagonalizável.

## Potências de Matrizes

**Teorema 5** *Se todo autovalor satisfaz  $|\lambda| < 1$ , então  $A^k \rightarrow 0$ , quando  $k \rightarrow +\infty$ .*



## Teorema Espectral

**Teorema 6** *Se  $A$  é uma matriz simétrica ( $A^T = A$ ), então existe uma matriz ortogonal  $Q$  tal que  $A = Q\Lambda Q^T$ , ou seja,  $A$  é diagonalizável.*

## Autovalores Reais

**Teorema 7** *Se  $A$  é simétrica, então seus autovalores são reais.*

**Corolário 7.1** *Se  $\lambda \in \mathbb{C}$  é autovalor de  $A$  e  $x$  é seu respectivo autovetor, então  $\bar{\lambda}$  é um autovalor de  $A$  (onde  $\overline{a + ib} = a - ib$ ) e  $\bar{x}$  é seu respectivo autovetor. Ou seja,  $Ax = \lambda x$  e  $A\bar{x} = \bar{\lambda}\bar{x}$  onde  $\lambda \in \mathbb{C}$*

## Autovetores Ortogonais

**Teorema 8** *Se  $A$  possui  $\lambda_1 \neq \lambda_2$ , com respectivos autovetores  $x_1, x_2$ , então  $x_1 \perp x_2$*

## Autovalores e Pivôs

**Lema 9** *O número de pivôs é igual ao número de autovalores não nulos.*

**Teorema 10** *Se  $A$  é simétrica, então os sinais dos autovalores e pivôs são iguais.*

## Equações Diferenciais (Aplicação da diagonalização)

Suponha que  $u(t)$  satisfaz a equação:

$$u'(t) = \lambda u(t)$$

A solução é  $u(t) = Ce^{\lambda t}$ , onde  $C$  é uma constante definida usando o valor de  $u(0)$ , por exemplo.

Podemos muitas equações então se escrevemos

$$\mathbf{u}(t) = \begin{bmatrix} u_1(t) \\ \vdots \\ u_n(t) \end{bmatrix}$$

E tomamos todas as equações na forma de matriz:

$$\mathbf{u}'(t) = A\mathbf{u}(t)$$

Onde  $A$  é uma matriz  $n \times n$  e  $\mathbf{u}(0)$  é dado. Suponha que  $A$  é diagonal, então as equações são desacopladas (e fica mais fácil resolver). Então no caso em que  $A$  é diagonalizável, a ideia é mudar de base usando os autovetores de  $A$  e resolver as equações desacopladas.

## Exponencial de Matriz (Aplicação)

Sabemos que

$$e^x = 1 + x + \frac{x^2}{2} + \cdots = \sum_{n=0}^{+\infty} \frac{x^n}{n!} \quad \forall x \in \mathbb{R}$$

A série (de Taylor) acima converge também se considerarmos uma matriz  $A$ :

$$e^A = 1 + A + \frac{A^2}{2} + \cdots = \sum_{n=0}^{+\infty} \frac{A^n}{n!}$$

**Lema 11** Se  $A = S\Lambda S^{-1}$ , então  $e^A = Se^\Lambda S^{-1}$

## $(I - A)^{-1}$ (Aplicação)

Suponha  $A$  é diagonalizável e  $|\lambda_i| < 1$  ( $\lambda_i$  é o  $i$ -ésimo autovetor de  $A$ ), assim  $A^n \rightarrow 0$  quando  $n \rightarrow +\infty$ . Então

$$(I - A)^{-1} = \sum_{n=0}^{+\infty} A^n = I - A^{-1} = I$$

## Equação de Segunda Ordem (Aplicação)

Considere a equação  $y''(t) + by'(t) + ky(t) = 0$ . Tome:

$$u(t) = \begin{bmatrix} y'(t) \\ y(t) \end{bmatrix}, A = u'(t) = \begin{bmatrix} y''(t) \\ y'(t) \end{bmatrix} = \begin{bmatrix} -b & -k \\ 1 & 0 \end{bmatrix} u(t)$$

E tome o polinômio característico  $p_A = \det(I - \lambda I) = \lambda^2 + b\lambda + k$ . Se existem  $\lambda_1, \lambda_2 \in \mathbb{R}$  raízes:

$$u(t) = Se^{\Lambda t}S^{-1}u(0)$$

Daí achamos  $y(t) = c_1e^{\lambda_1 t} + c_2e^{\lambda_2 t}$ , onde  $c_1, c_2$  são constantes e dependem de  $A$  que depende de  $b, k$ .

## Formas Quadráticas

Uma forma quadrática em  $\mathbb{R}^2$  é uma equação da forma

$$ax^2 + 2bxy + cy^2 = 1$$

**Definição 2** *Uma forma quadrática em  $\mathbb{R}^n$  é definida como (supondo  $A$  simétrico)*

$$q(x) = x^T Ax = \sum_{i,j=1}^n a_{ij}x_i x_j$$

E usando o Teorema Espectral  $x^T Ax = y^T \Lambda y = \sum_{i=1}^n \lambda_i y_i^2$  onde  $y = Q^T$  (ou  $y_i = q_i^T x$ )

## Positiva Definida

**Definição 3** *Diremos que  $A$  é **positiva definida** se  $x^T Ax > 0$ . A matriz  $A$  é dita **positiva semi-definida** se  $x^T Ax \leq 0$*

**Teorema 12**  *$A$  é positiva definida se e somente se todos seus autovalores são estritamente positivos.*

Propriedade: Se  $A$  e  $B$  são positivas definidas, então  $A + B$  é positiva definida.

## Raiz Quadrada (Aplicação de matriz positiva definida)

Suponha que  $A$  é uma matriz positiva definida ( $A$  é simétrica). Diremos que  $R$  é raiz quadrada de  $A$  se  $A = R^T R$ . Se  $A = Q \Lambda Q^T$ , então  $R = \sqrt{\Lambda} Q^T$ .

## Decomposição de Cholesky

**Definição 4** Dada uma matriz positiva definida  $A$ , a sua decomposição de Cholesky é uma raiz quadrada triangular inferior,  $A = CC^T$ .

## Matrizes Similares (generalização de diagonalização)

**Definição 5**  $A$  e  $B$  são ditas **similares** se existe uma matriz invertível  $M$  tal que  $A = MBM^{-1}$ .

**Teorema 13** Matrizes similares tem os mesmos autovalores (mas autovetores mudam).

**Corolário 13.1** Matrizes similares tem o mesmo determinante, o mesmo número de autovetores independentes e uma é diagonalizável se e só se a outra também é.

## Decomposição em Valores Singulares - SVD

Pode ser entendido com uma generalização do Teorema Espectral para matrizes retangulares.

**Teorema 14** Sendo  $A_{m \times n}$  existem matrizes ortogonais  $U_{m \times m}$  e  $V_{n \times n}$  e uma matriz diagonal  $\Sigma_{m \times n}$  com diagonal positiva tais que  $A = U\Sigma V^T$ .

Vamos definir  $U, V$  e  $\Sigma$ .

- Defina  $\sigma_j = \sqrt{\lambda_j}$ , que chamamos de valores singulares de  $A$ .
- Para  $j = 1, \dots, r$ , definimos

$$u_j = \frac{Aq_j}{\sigma_j}$$

- Complete a base ortonormal com  $u_{r+1}, \dots, u_n$
- $\Sigma$  é uma matriz diagonal com  $\Sigma_{jj} = \sigma_j$
- E  $V = Q$ . Logo

$$U\Sigma = [\sigma_1 u_1 \quad \dots \quad \sigma_r u_r \quad 0 \quad \dots \quad 0] = [Aq_1 \quad \dots \quad Aq_r \quad \dots \quad Aq_n] = AV$$

## Exemplo de SVD

Encontrar  $U, V, \Sigma$  para a matriz  $A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$ .

$$A^T A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

Calculando os autovalores fica  $\lambda_1 = 3$  e  $\lambda_2 = 1$  e então temos os valores singulares  $\sigma_1 = \sqrt{3}$  e  $\sigma_2 = 1$ .

Temos  $V = Q = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$ , note que a posição dos autovetores  $q_1$  e  $q_2$  na matriz  $Q$  é de acordo com os autovalores.

$$\text{E } \Sigma = \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}, \text{ diagonal com os valores singulares.}$$

Como  $U$  é  $3 \times 3$ , vamos calcular  $u_1, u_2$  e  $u_3$

$$u_1 = \frac{Aq_1}{\sigma_1} = \begin{bmatrix} \frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \end{bmatrix}$$

$$u_2 = \frac{Aq_2}{\sigma_2} = \begin{bmatrix} 0 \\ -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

$$u_3 = e_1 - (e_1^T u_1)u_1 - (e_1^T u_2)u_2 = \begin{bmatrix} \frac{1}{3} \\ -\frac{1}{3} \\ -\frac{1}{3} \end{bmatrix}$$

Note que  $u_3$  não está normalizado, então normalizando  $u_3$  a matriz fica

$$U = \begin{bmatrix} \frac{2}{\sqrt{6}} & 0 & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} \end{bmatrix}$$

## SVD - Bases dos Espaços Fundamentais

Sendo  $A = U\Sigma V^T$

- $v_1, \dots, v_r$  é uma base ortonormal para  $C(A^T)$ .

- $u_1, \dots, u_r$  é uma base ortonormal para  $C(A)$ .
- $v_{r+1}, \dots, v_n$  é uma base ortonormal para  $N(A)$ .
- $u_{r+1}, \dots, u_n$  é uma base ortonormal para  $N(A^T)$

## SVD - Mínimos Quadrados

Queremos calcular  $\min_x \|Ax - b\|$ , a solução em mínimos quadrados fica:

$$x^* = \sum_{i=1}^r \frac{u_i^T b}{\sigma_i} v_i$$

## Transformações Lineares

**Definição 6** *Sejam  $U$  e  $V$  dois espaços vetoriais. Diremos que  $T : U \rightarrow V$  é uma **transformação linear** se*

- $T(u + v) = T(u) + T(v)$
- $T(\alpha u) = \alpha T(u)$

**Teorema 15** *Se  $\dim U = n$ , seja  $\{u_1, \dots, u_n\}$  uma base de  $U$ , então*

$$T(u) = x_1 T(u_1) + \dots + x_n T(u_n)$$

Onde  $u = x_1 u_1 + \dots + x_n u_n$

Podemos escrever uma certa