

## Resumo Titica

### Aula 1 - O que é e para que serve Inferência Estatística?

**Definição 1 (Modelo estatístico: informal)** Um *modelo estatístico* consiste na identificação de variáveis aleatórias de interesse (observáveis e potencialmente observáveis), na especificação de uma distribuição conjunta para as variáveis aleatórias observáveis e na identificação dos parâmetros ( $\theta$ ) desta distribuição conjunta. Às vezes é conveniente assumir que os parâmetros são variáveis aleatórias também, mas para isso é preciso especificar uma distribuição conjunta para  $\theta$ .

**Definição 2 (Modelo estatístico: formal)** Seja  $\mathcal{X}$  um espaço amostral qualquer,  $\Theta$  um conjunto não-vazio arbitrário e  $\mathcal{P}(\mathcal{X})$  o conjunto de todas as distribuições de probabilidade em  $\mathcal{X}$ . Um modelo estatístico *paramétrico* é uma função  $P : \Theta \rightarrow \mathcal{P}(\mathcal{X})$  que associa a cada  $\theta \in \Theta$  uma distribuição de probabilidade  $P_\theta$  em  $\mathcal{X}$ .

**Definição 3 (Afirmção probabilística)** Dizemos que uma afirmação é *probabilística* quando ela utiliza conceitos da teoria de probabilidade para falar de um objeto.

**Definição 4 (Inferência Estatística)** Uma *inferência estatística* é uma *afirmação probabilística* sobre uma ou mais partes de um modelo estatístico.

**Definição 5 (Estatística)** Suponha que temos uma coleção de variáveis aleatórias  $X_1, X_2, \dots, X_n \subseteq \mathbf{R}^n$  e uma função  $r : \mathbf{X} \rightarrow \mathbf{R}^m$ . Dizemos que a variável aleatória  $T = r(X_1, X_2, \dots, X_n)$  é uma *estatística*.

**Definição 6 (Permutabilidade)** Uma coleção finita de variáveis aleatórias  $X_1, X_2, \dots, X_n$  com densidade conjunta  $f$  é dita *permutável* se

$$f(x_1, x_2, \dots, x_n) = f(x_{\pi(1)}, x_{\pi(2)}, \dots, x_{\pi(n)}) \quad (1)$$

para qualquer permutação  $\pi = \{\pi(1), \pi(2), \dots, \pi(n)\}$  dos seus elementos. Uma coleção finita é permutável se qualquer subconjunto finito é permutável.

### Aula 2 - Distribuição a priori e a posteriori

**Definição 7 (Distribuição a priori)** Se tratamos o parâmetro  $\theta$  como uma variável aleatória, então a *distribuição a priori* é a distribuição que damos a  $\theta$  antes de observarmos as outras variáveis aleatórias de interesse. Vamos denotar a função de densidade/massa de probabilidade da priori por  $\xi(\theta)$ .

**Definição 8 (Distribuição a posteriori)** Considere o problema estatístico com parâmetros  $\theta$  e variáveis aleatórias observáveis  $X_1, X_2, \dots, X_n$ . A distribuição condicional de  $\theta$  dados os valores observados das variáveis aleatórias,  $\mathbf{x} := \{x_1, x_2, \dots, x_n\}$  é a *distribuição a posteriori* de  $\theta$ , denotamos por  $\xi(\theta | \mathbf{x})$  a f.d.p./f.m.p. condicional a  $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ .

**Teorema 1 (Distribuição a posteriori: derivação)** Considere a amostra aleatória  $X_1, X_2, \dots, X_n$  de uma distribuição com f.d.p./f.m.p.  $f(x | \theta)$ . Se a distribuição a priori é  $\xi(\theta)$ , temos

$$\xi(\theta | x) = \frac{\xi(\theta) \prod_{i=1}^n f(x_i | \theta)}{g_n(x)}, \quad \theta \in \Omega \quad (2)$$

Chamamos  $g_n(x)$  de distribuição marginal de  $X_1, X_2, \dots, X_n$ .

**Definição 9 (Função de verossimilhança)** Quando encaramos a f.d.p./f.m.p.  $f(x_1, x_2, \dots, x_n | \theta)$  como uma função do parâmetro  $\theta$ , chamamos esta função de **função de verossimilhança**, e podemos denotá-la como  $L(\theta; x)$  ou, quando a notação não criar ambiguidade, simplesmente  $L(\theta)$ .

## Aula 3 - Prioris conjugadas e função de perda

**Definição 10 (Hiper-parâmetros)** Seja  $\xi(\theta | \phi)$  a distribuição a priori para o parâmetro  $\theta$ , indexada por  $\phi \in \Phi$ . Dizemos que  $\phi$  é(são) o(s) **hiper-parâmetro(s)** da priori de  $\theta$ .

**Definição 11 (Priori conjugada)** Suponha que  $X_1, X_2, \dots$  sejam condicionalmente independentes dado  $\theta$ , com f.d.p./f.m.p.  $f(x | \theta)$ . Defina

$$\Psi = \left\{ f : \Omega \rightarrow (0, \infty), \int_{\Omega} f dx = 1 \right\} \quad (3)$$

onde  $\Omega$  é o espaço de parâmetros. Dizemos que  $\Psi$  é uma **família de distribuições conjugadas** para  $f(x | \theta)$  se  $\forall f \in \Psi$  e toda realização  $\mathbf{x}$  de  $X = X_1, X_2, \dots, X_n$

$$\frac{f(\mathbf{x} | \theta) f(\theta)}{\int_{\Omega} f(\mathbf{x} | \theta) f(\theta) d\theta} \in \Psi \quad (4)$$

**Teorema 2 (Distribuição a posteriori da média de uma normal)** Suponha que  $X_1, X_2, \dots, X_n$  formam uma amostra aleatória com distribuição normal e com média desconhecida  $\theta$  e variância  $\sigma^2 > 0$ , conhecida e fixa. Suponha que  $\theta \sim \text{Normal}(\mu_0, v_0^2)$  a priori. Então

$$\xi(\theta | x, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\theta - \mu_1)^2}{2v_1^2}\right), \quad (5)$$

onde

$$\mu_1 := \frac{\sigma^2 \mu_0 + n v_0^2 \bar{x}_n}{\sigma^2 + n v_0^2} \text{ e } v_1^2 := \frac{\sigma^2 v_0^2}{\sigma^2 + n v_0^2} \quad (6)$$

**Definição 12 (Priori imprópria)** Seja  $\xi : \Lambda \rightarrow (0, \infty), \Lambda \subseteq \Lambda$ , uma função tal que  $\int_{\Omega} \xi(\theta) d\theta = \infty$ . Se utilizamos  $\xi$  como uma p.d.f.<sup>1</sup> para  $\theta$ , dizemos que  $\xi$  é uma **priori imprópria** para  $\theta$ .

**Definição 13 (Estimador)** Sejam  $X_1, X_2, \dots, X_n$  variáveis aleatórias com distribuição conjunta indexada por  $\theta$ . Um **estimador** de  $\theta$  é qualquer função real  $\delta : X_1, X_2, \dots, X_n \rightarrow \mathbb{R}^d, d \geq 1$ .

**Definição 14 (Estimativa)** Dizemos que o valor de  $\delta$  avaliado nas realizações de  $X_1, X_2, \dots, X_n$ ,  $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$ ,  $\delta(\mathbf{x})$  é uma **estimativa** de  $\theta$ .

**Definição 15 (Função de perda)** Uma função de perda é uma função real em duas variáveis

$$L : \Omega \times \mathbb{R}^d \rightarrow \mathbb{R}, \quad (7)$$

em que dizemos que o estatístico perde  $L(\theta, a)$  se o parâmetro vale  $\theta$  e a estimativa dada vale  $a$ .

<sup>1</sup>p.d.f. - "probability density function" ou função de densidade de probabilidade

## Aula 4 - Estimadores de Bayes e EMV

**Definição 16 (Estimador de Bayes)** Considere a perda esperada a posteriori:

$$E_{\theta|x}[L(\theta, a)] = E[L(\theta, a) | x] = \int_{\Omega} L(\theta, a) \xi(\theta | x) d\theta \quad (8)$$

Dizemos que  $\delta^*$  é um **estimador de Bayes** se, para toda realização  $X = x$ ,

$$E[L(\theta, \delta^*(x)) | x] = \min_{a \in A} E[L(\theta, a) | x]. \quad (9)$$

Em outras palavras, um estimador de Bayes é uma função real dos dados que minimiza a perda esperada com respeito à posteriori dos parâmetros.

**Teorema 3 ( $\delta^*$  sob perda quadrática)** Seja  $\theta$  um parâmetro tomando valores reais. Sob perda quadrática,

$$\delta^*(x) = E[\theta | X = x] = \int_{\Omega} \theta \xi(\theta | x) d\theta \quad (10)$$

**Teorema 4 ( $\delta^*$  sob perda absoluta)** Suponha que a função de perda é dada por

$$L(\theta, \delta^*) = |\theta - \delta^*|. \quad (11)$$

Dizemos que a função de perda é **absoluta**. Seja  $\theta$  um parâmetro tomando valores na reta. Sob perda absoluta,  $\delta^*(x)$  é a **mediana a posteriori**, isto é,

$$\int_{-\infty}^{\delta^*(x)} \xi(\theta | x) d\theta = \frac{1}{2} \quad (12)$$

**Definição 17 (Estimador consistente)** Seja  $\delta_1, \delta_2, \dots, \delta_n$  uma sequência de estimadores de  $\theta$ . Se quando  $n \rightarrow \infty$  a sequência convergente para  $\theta$ , dizemos que esta é uma **sequência consistente de estimadores**.

**Definição 18 (Estimador de máxima verossimilhança)** Para cada possível vetor (de observações)  $x$ , seja  $\delta(x) \in \Omega$  um valor de  $\theta \in \Omega$  de modo que a função de verossimilhança,  $L(\theta) \propto f(x | \theta)$ <sup>2</sup>, atinge o máximo. Dizemos que  $\hat{\theta} = \delta(\mathbf{X})$  é o **estimador de máxima verossimilhança** de  $\theta$  (Fisher, 1922)<sup>3</sup>. Quando observamos  $\mathbf{X} = x$ , dizemos que  $\delta(x)$  é uma estimativa de  $\theta$ . Dito de outra forma:

$$\max_{\theta \in \Omega} f(\mathbf{X} | \theta) = f(\mathbf{X} | \hat{\theta}). \quad (13)$$

## Famílias Conjugadas

Se  $X_1, \dots, X_n$  são iid e seguem a distribuição da coluna “Dados” na tabela 1.

**Notações:**  $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$ ;  $y = \sum_{i=1}^n x_i$

Dados	Priori	Posteriori
$Bernoulli(\theta)$	$Beta(\alpha, \beta)$	$Beta(\alpha + y, \beta + n - y)$
$Poisson(\theta)$	$Gama(\alpha, \beta)$	$Gama(\alpha + y, \beta + n)$
$Normal(\mu, \sigma^2)$	$Normal(\mu_0, v_0^2)$	$Normal(\sigma^2 \mu_0 + n v_0^2 \bar{x}_n \sigma^2 + n v_0^2 \sigma^2 v_0^2 \sigma^2 + n v_0^2)$
$Exp(\theta)$	$Gama(\alpha, \beta)$	$Gama(\alpha + n, \beta + y)$

Table 1: Famílias Conjugadas

<sup>2</sup> $\propto$  - é um operador matemático binário que indica que o valor esquerdo é proporcional ao valor direito.

<sup>3</sup>Ronald Aylmer Fisher (1890-1962), biólogo e estatístico inglês.

## Aula 5 - EMV (parte II)

**Teorema 5 (Invariância do EMV)** Considere uma função  $\phi : \Omega \rightarrow \mathbb{R}$ . Se  $\hat{\theta}$  é um EMV para  $\theta$ , então  $\phi(\hat{\theta})$  é um EMV para  $\omega = \phi(\theta)$ .

**Teorema 6 (Consistência do EMV)** Defina  $l(\theta) := \log f_n(x | \theta)$  e assumamos que  $X_1, \dots, X_n \sim f(\theta_0)$ , isto é, que  $\theta_0$  é o valor verdadeiro do parâmetro. Denote  $E_{\theta_0}[g] := \int_{\mathcal{X}} g(x, \theta_0) f(x | \theta_0) dx$ . Suponha que

- $f(x_i | \theta)$  tem o mesmo suporte;
- $\theta_0$  é o ponto inferior de  $\Omega$ ;
- $I(\theta)$  é diferenciável;
- $\hat{\theta}_{EMV}$  é única solução de  $I'(\theta) = 0$ .

Então

$$\hat{\theta}_{EMV} \rightarrow \theta$$

## Aula 6 - Método dos momentos e suficiência

**Definição 19 (Método dos momentos)** Suponha que  $X_1, \dots, X_n$  formam uma sequência aleatória com distribuição conjunta  $f_n(X_1, \dots, X_n | \theta)$ ,  $\theta \in \Omega \subseteq \mathbb{R}^k$  e que o  $k$ -ésimo momento existe. Defina  $\mu_j(\theta) = E[X_1^j | \theta]$  e suponha que  $\mu : \Omega \rightarrow \mathbb{R}^k$  é biunívoca, de modo que sua inversa é

$$\theta = M(\mu_1(\theta), \dots, \mu_k(\theta)).$$

Dados os momentos amostrais  $m_j := \frac{1}{n} \sum_{i=1}^n X_i^j$ ,  $j = 1, \dots, k$  o **estimador de momentos (EMM)** de  $\theta$  é

$$\hat{\theta}_{EMM} = M(m_1, \dots, m_k).$$

**Teorema 7 (Consistência do EMM)** Suponha que  $X_1, \dots, X_n$  formam uma amostra aleatória com distribuição conjunta  $f_n(X_1, \dots, X_n | \theta)$ ,  $\theta \in \Omega \subseteq \mathbb{R}^k$  e que o  $k$ -ésimo momento existe. Suponha que a inversa  $M$  existe e é contínua. Então o EMM é **consistente** para  $\theta$ .

**Definição 20 (Estatística suficiente)** Seja  $X_1, \dots, X_n$  uma amostra aleatória de uma distribuição indexada pelo parâmetro  $\theta$ . Seja  $T = r(X_1, \dots, X_n)$  uma estatística. Dizemos que  $T$  é uma **estatística suficiente** para  $\theta$  se e somente se

$$f(X_1, \dots, X_n | T = t, \theta) = f(X_1, \dots, X_n | T = t, \theta'), \forall \theta, \theta' \in \Omega, \quad (14)$$

isto é, se a distribuição condicional da amostra dado o valor da estatística não depende de  $\theta$ .

**Definição 21 (Aleatorização auxiliar)** Suponha que  $T$  é suficiente para  $\theta$ . O processo de simular  $X'_1, \dots, X'_n$  dado que  $T = r(X_1, \dots, X_n)$  de modo que

$$f(X_1, \dots, X_n | \theta) = f(X'_1, \dots, X'_n | \theta), \forall \theta \in \Omega, \quad (15)$$

é chamado de **aleatorização auxiliar** (em inglês, *auxiliary randomisation*).

**Teorema 8 (Teorema de fatorização)** Suponha que  $X_1, \dots, X_n$  perfazem uma amostra aleatória com f.d.p./f.m.p.f.  $f(x | \theta)$ ,  $\theta \in \Omega$ . Uma estatística  $T = r(X_1, \dots, X_n)$  é suficiente para  $\theta$  se, e somente se, para todo  $x \in \mathcal{X}$  e  $\theta \in \Omega$  existem  $u$  e  $v$  não negativos tal que

$$f_n(x | \theta) = u(x)v[r(x), \theta]. \quad (16)$$

**Definição 22 (Suficiência conjunta)** Dizemos que um conjunto de estatísticas  $T = \{T_1, \dots, T_n\}$  é **suficiente** (conjuntamente) se que a distribuição condicional conjunta de  $X_1, \dots, X_n$  dado  $T_1 = t_1, \dots, T_n = t_n$  não dependem de  $\theta$ .

## Aula 7 - Suficiência conjunta e mínima, teorema de Rao-Blackwell

**Definição 23 (Estatísticas de ordem)** Seja  $\mathbf{X} = X_1, \dots, X_n$  uma amostra aleatória. Dizemos que  $Y_1, \dots, Y_n$  são **estatísticas de ordem** se  $Y_1$  é o menor valor de  $\mathbf{X}$ ,  $Y_2$  é o segundo menor valor e assim sucessivamente.

**Teorema 9 (Estatísticas de ordem são suficientes conjuntas)** Seja  $X_1, \dots, X_n$  uma amostra aleatória com f.d.p./f.m.p.  $f(x | \theta)$ . As estatísticas de ordem  $Y_1, \dots, Y_n$  são suficientes conjuntas para  $\theta$ .

**Definição 24 (Suficiência mínima)** Uma estatística  $\mathbf{T}$  é dita **mínima suficiente** se  $\mathbf{T}$  é suficiente e é função de qualquer outra estatística suficiente. Um vetor  $\mathbf{T} = \{T_1, \dots, T_n\}$  é dito **minimamente suficiente conjunto** se é função de qualquer outro valor de estatísticas suficientes conjuntas.

**Teorema 10 (EMV e Bayes são suficientes)** Se a função de verossimilhança admite fatorização pelo Teorema 8, os estimadores de Bayes e de máxima verossimilhança são estatísticas minimamente suficientes.

**Definição 25 (Notação conveniente)** É conveniente definir que para  $g : \mathcal{X}^n \rightarrow \mathbb{R}$ , escrevemos

$$E_\theta[g] = \int_{\mathcal{X}} \cdots \int_{\mathcal{X}} g(\mathbf{x}) f_n(\mathbf{x} | \theta) dx_1 \cdots dx_n = \int_{\mathcal{X}} g(\mathbf{x}) f_n(\mathbf{x} | \theta) d\mathbf{x} \quad (17)$$

**Definição 26 (Erro quadrático médio)**

$$R(\theta, \delta) := E_\theta [\{\delta(\mathbf{X}) - \theta\}^2]. \quad (18)$$

**Definição 27 (Estimador condicionado)**

$$\delta_0(\mathbf{T}) := E_\theta [\delta(\mathbf{X}) | \mathbf{T}]. \quad (19)$$

**Teorema 11 (Teorema de Rao-Blackwell)** Seja  $\delta(\mathbf{X})$  um estimador,  $\mathbf{T}$  uma estatística suficiente para  $\theta$  e seja  $\delta_0(\mathbf{T})$  como na Definição 27. Então vale que

$$R(\theta, \delta_0) \leq R(\theta, \delta)$$

Além disso, se  $R(\theta, \delta) < \infty$  e  $\delta(\mathbf{X})$  não é função de  $\mathbf{T}$ , vale a desigualdade estrita:

$$R(\theta, \delta_0) < R(\theta, \delta)$$

## Aula 8 - Admissibilidade e viés

**Definição 28 (Admissibilidade)** Um estimador  $\delta$  é dito **inadmissível** se existe outro estimador  $\delta_0$  tal que  $R(\theta, \delta_0) \leq R(\theta, \delta), \forall \theta \in \Omega$  e existe  $\theta' \in \Omega$  tal que  $R(\theta', \delta_0) < R(\theta', \delta)$ . Nesse caso, dizemos que  $\delta_0$  domina  $\delta$ . O estimador  $\delta_0$  é **admissível** se (e somente se) não há nenhum estimador que o domine.

**Definição 29 (Estimador não-viesado)** Um estimador  $\delta(\mathbf{X})$  de uma função  $g(\theta)$  é dito **não-viesado** se  $E_\theta[\delta(\mathbf{X})] = g(\theta), \forall \theta \in \Omega$ . Um estimador que não atende a essa condição é dito **viesado**. E o **viés** de  $\delta$  é definido como  $B_\delta(\theta) := E_\theta[\delta(\mathbf{X})] - g(\theta)$ .

**Teorema 12 (Estimador não-viesado da variância)** Seja  $\mathbf{X} = \{X_1, \dots, X_n\}$  uma amostra aleatória, com  $E[X_1] = m$  e  $Var(X_1) = v < \infty$ . Então

$$\delta_1(\mathbf{X}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

é um estimador não-viesado de  $v$ .

## Aula 9 - Eficiência

**Definição 30 (Informação de Fisher)** Seja  $X$  uma variável aleatória com f.d.p./f.m.p.  $f(x | \theta)$ ,  $\theta \in \Omega \subseteq \mathbb{R}$ . Suponha que  $f(x | \theta)$  é duas vezes diferenciável com respeito a  $\theta$ . Defina  $\lambda(x | \theta) = \log f(x | \theta)$  e

$$\lambda'(x | \theta) = \frac{\partial \lambda(x | \theta)}{\partial \theta} \quad \text{e} \quad \lambda''(x | \theta) = \frac{\partial^2 \lambda(x | \theta)}{\partial \theta^2} \quad (20)$$

Definimos a **informação de Fisher** como

$$I(\theta) = E_{\theta} [\{\lambda'(x | \theta)\}^2] \stackrel{(1)}{=} -E_{\theta} [\lambda''(x | \theta)] = \text{Var}_{\theta} (\lambda'(x | \theta)). \quad (21)$$

**Teorema 13 (Informação de Fisher em uma amostra aleatória)** Seja  $\mathbf{X} = \{X_1, \dots, X_n\}$  uma amostra aleatória e seja  $I_n = E_{\theta} [-\lambda''_n(\mathbf{X} | \theta)]$  a **informação de Fisher** da amostra. Então

$$I_n(\theta) = nI(\theta)$$

**Teorema 14 (Teorema de Cramér-Rao)** Seja  $\mathbf{X} = \{X_1, \dots, X_n\}$  uma amostra aleatória, onde f.d.p./f.m.p. tem as mesmas premissas da Definição 30. Supondo que  $T = r(\mathbf{X})$  é uma estatística com variância finita. Seja  $m(\theta) = E_{\theta}(T)$  uma função diferenciável de  $\theta$ . Então,

$$\text{Var}_{\theta}(T) \geq \frac{[m'(\theta)]^2}{nI(\theta)}, \quad (22)$$

com igualdade apenas se existem  $u$  e  $v$  tal que

$$T = u(\theta)\lambda'_n(\mathbf{X} | \theta) + v(\theta).$$

**Definição 31 (Estimador eficiente)** Um estimador  $\delta(\mathbf{X})$  é dito **eficiente** de (sua esperança)  $m(\theta)$  se

$$\text{Var}_{\theta}(\delta) = \frac{[m'(\theta)]^2}{nI(\theta)}.$$

## Aula 10 - Distribuição de uma estatística amostral e qui-quadrado

**Definição 32 (Distribuição qui-quadrado)** Dizemos que uma variável aleatória  $Y$  tem distribuição **qui-quadrado** com  $m$  graus de liberdade quando

$$f_Y(y) = \frac{1}{2^{m/2}\Gamma(m/2)} y^{m/2-1} e^{-y/2}, y > 0 \quad (23)$$

Vemos que  $Y$  tem função geradora de momentos:

$$\psi(t) = \left( \frac{1}{1-2t} \right)^{m/2}, t < 1/2.$$

**Teorema 15 (Soma de variáveis aleatórias qui-quadrado)** Se  $X_1, \dots, X_n$  são variáveis aleatórias independentes com graus de liberdade  $m_i$ , então  $W = \sum_{i=1}^n X_i$  tem distribuição qui-quadrado com graus de liberdade  $m = \sum_{i=1}^n m_i$ .

**Teorema 16 (Distribuição do quadrado de uma variável aleatória Normal padrão)** Se

$$X \sim \text{Normal}(0, 1), Y = X^2$$

então, tem distribuição qui-quadrado com  $m = 1$ .

## Aula 11 - Distribuição da média e variância amostrais

**Teorema 17 (Independência da média e variância amostrais na Normal)** *Seja  $X_1, \dots, X_n$  uma amostra aleatória de uma distribuição Normal com parâmetros  $\mu$  e  $\sigma^2$ ,  $\bar{X}_n$  e a variância amostral  $\bar{S}_n^2$ , são independentes. Ademais,  $\bar{X}_n \sim \text{Normal}(\mu, \sigma^2)$  e  $\bar{S}_n^2 \sim \text{Gama}(\frac{n-1}{2}, \frac{n}{2n^2})$*

## Aula 12 - Distribuição t de Student e intervalos de confiança